

Analisis Perbandingan K-Means Dasar dan Incremental K-Means pada Segmentasi Plak Citra Gigi

Fitri Nur Aini¹, Camellia Mardatilla Wirantono², Salsabila Arsa Azura³, Elly Matul Imah⁴

¹Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014080@mhs.unesa.ac.id

²Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014051@mhs.unesa.ac.id

³Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, 60231, email: 25032014085@mhs.unesa.ac.id

⁴Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Surabaya, Surabaya, 60231, email: ellymatul@unesa.ac.id

CORRESPONDING AUTHOR: Fitri Nur Aini

INTISARI — Kesehatan gigi dan mulut sering kali terganggu oleh akumulasi plak yang dapat memicu berbagai penyakit periodontal jika tidak ditangani. Identifikasi dini melalui pengolahan citra digital, khususnya melalui teknik segmentasi, menjadi langkah analisis preventif yang krusial. Penelitian ini bertujuan untuk membandingkan performa algoritma K-Means Dasar dan *Incremental K-Means* pada segmentasi citra plak gigi, dengan mengevaluasi pengaruh tiga metrik pengukuran jarak Euclidean, Manhattan, dan Minkowski. Tahapan metodologi mencakup akuisisi citra, *preprocessing* (penyesuaian resolusi, konversi ruang warna RGB, dan normalisasi), penentuan parameter *cluster* menggunakan metode Elbow dan *Silhouette Score*, pelaksanaan segmentasi, serta analisis evaluasi. Pengujian menunjukkan bahwa jumlah *cluster* (K) optimal untuk dataset yang digunakan adalah 2. Berdasarkan hasil analisis perbandingan, K-Means Dasar terbukti jauh lebih unggul secara efisiensi waktu maupun kualitas hasil dibandingkan *Incremental K-Means*. K-Means Dasar mencatatkan waktu komputasi tercepat sebesar 0,07 detik pada penggunaan metrik jarak Manhattan, serta menghasilkan *Silhouette Score* yang stabil di kisaran 0,51 pada seluruh skenario metrik jarak. Sebaliknya, metode *Incremental K-Means* mencatatkan waktu komputasi yang lebih lama (hingga 2,06 detik) dengan skor segmentasi yang berfluktuasi dan lebih rendah. Penelitian ini menyimpulkan bahwa metode K-Means Dasar konvensional memiliki tingkat keandalan yang lebih tinggi untuk aplikasi segmentasi citra plak gigi dibandingkan varian inkrementalnya.

KATA KUNCI — *Incremental K-Means*, *K-Means Clustering*, Metrik Jarak, Plak Gigi, Segmentasi Citra

I. PENDAHULUAN

Kesehatan gigi dan mulut merupakan salah satu aspek penting dalam menjaga kesehatan tubuh secara keseluruhan. Salah satu permasalahan yang sering terjadi adalah terbentuknya plak gigi, yaitu lapisan tipis yang terdiri dari kumpulan bakteri dan sisa makanan yang menempel pada permukaan gigi. Jika tidak dibersihkan secara rutin, plak dapat menyebabkan berbagai gangguan kesehatan gigi seperti karies, radang gusi, hingga penyakit periodontal. Oleh karena itu, identifikasi dan deteksi plak gigi sejak dini menjadi langkah penting untuk mendukung tindakan pencegahan dan perawatan kesehatan gigi [1]. Permasalahan kesehatan gigi dan mulut masih menjadi isu kesehatan yang cukup besar di dunia. Menurut laporan *World Health Organization* (WHO), penyakit gigi dan mulut diperkirakan memengaruhi sekitar 3,7 miliar penduduk dunia. Selain itu, karies gigi yang tidak ditangani menjadi salah satu kondisi kesehatan paling umum secara global. Salah satu faktor utama yang berkontribusi terhadap terjadinya karies dan penyakit periodontal adalah akumulasi plak pada permukaan gigi akibat kebersihan gigi dan mulut yang kurang terjaga. Kondisi tersebut menunjukkan pentingnya identifikasi dan pemantauan plak gigi secara dini untuk mengurangi risiko terjadinya gangguan kesehatan gigi yang lebih serius [2].

Perkembangan teknologi pengolahan citra digital memungkinkan proses identifikasi objek pada citra dilakukan secara otomatis. Salah satu tahapan penting dalam pengolahan citra adalah segmentasi citra, yaitu proses memisahkan objek tertentu dari latar belakang atau area lain berdasarkan karakteristik tertentu seperti warna, intensitas, maupun tekstur. Segmentasi citra berperan penting karena hasil segmentasi yang baik dapat membantu proses analisis dan identifikasi objek secara lebih akurat. Metode *clustering* merupakan salah satu pendekatan yang banyak digunakan dalam segmentasi citra. K-Means *Clustering* menjadi salah satu algoritma yang populer

karena memiliki konsep sederhana, mudah diimplementasikan, serta mampu mengelompokkan data berdasarkan kemiripan karakteristik tertentu. Pada segmentasi citra, K-Means bekerja dengan mengelompokkan piksel-piksel yang memiliki karakteristik warna atau intensitas yang serupa ke dalam beberapa *cluster* sehingga objek yang ingin diamati dapat dipisahkan dari area lainnya. Berbagai penelitian menunjukkan bahwa K-Means mampu menghasilkan segmentasi citra yang cukup baik pada berbagai bidang aplikasi, termasuk citra medis dan citra berwarna [3].


Meskipun demikian, K-Means dasar memiliki kelemahan yaitu jumlah *cluster* (K) harus ditentukan terlebih dahulu sebelum proses *clustering* dilakukan. Penentuan nilai K yang kurang tepat dapat memengaruhi kualitas segmentasi yang dihasilkan. Untuk mengatasi permasalahan tersebut, dikembangkan pendekatan *Incremental K-Means* yang memungkinkan pembentukan *cluster* secara bertahap berdasarkan kondisi data tertentu sehingga jumlah *cluster* tidak harus ditentukan sejak awal. Pendekatan ini diharapkan mampu memberikan fleksibilitas yang lebih baik dalam proses pengelompokan data serta mengurangi ketergantungan terhadap penentuan jumlah *cluster* secara manual [4]. Selain jumlah *cluster*, pemilihan metode pengukuran jarak juga menjadi faktor yang memengaruhi hasil *clustering*. Beberapa metrik jarak yang umum digunakan adalah jarak Euclidean, Manhattan, dan Minkowski. Masing-masing metode memiliki karakteristik perhitungan yang berbeda sehingga dapat menghasilkan kualitas segmentasi dan performa komputasi yang berbeda. Oleh karena itu, analisis terhadap pengaruh penggunaan metrik jarak pada proses *clustering* menjadi penting untuk mengetahui metode yang paling sesuai pada segmentasi plak citra gigi [5].

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk melakukan analisis perbandingan antara algoritma K-

Means dan *Incremental K-Means* pada segmentasi plak citra gigi dengan menggunakan tiga metode pengukuran jarak, yaitu Euclidean, Manhattan, dan Minkowski. Hasil penelitian ini diharapkan dapat memberikan informasi mengenai metode yang menghasilkan performa terbaik berdasarkan kualitas segmentasi maupun efisiensi proses komputasi sehingga dapat menjadi referensi dalam pengembangan sistem segmentasi citra gigi berbasis *clustering*.

II. METODE PENELITIAN

Secara garis besar penelitian ini dilakukan dalam lima tahapan utama, yaitu akuisisi data citra, *preprocessing* citra, segmentasi menggunakan algoritma *clustering*, evaluasi hasil segmentasi, dan analisis perbandingan performa. Metodologi penelitian yang digunakan peneliti digambarkan dalam diagram alir seperti pada Gambar 1 di bawah ini:



Gambar 1. Diagram Alir Penelitian

1) AKUISISI DATA CITRA

Data yang digunakan dalam penelitian ini berupa citra gigi yang mengandung area plak. Dataset citra diperoleh dari dataset segmentasi plak gigi yang tersedia dalam format citra berwarna RGB. Setiap citra digunakan sebagai masukan untuk proses segmentasi menggunakan algoritma K-Means Dasar dan *Incremental K-Means*.

2) PREPROCESSING CITRA

Tahap *preprocessing* dilakukan untuk mempersiapkan data sebelum proses segmentasi. Citra diubah terlebih dahulu ukurannya menjadi 150×150 piksel untuk mengurangi kompleksitas komputasi dan mempercepat proses pengolahan data. Selanjutnya citra dikonversi dari format warna BGR menjadi RGB. Setelah proses konversi warna selesai, citra direpresentasikan dalam bentuk matriks piksel tiga kanal warna (*Red, Green, Blue*). Nilai piksel kemudian dinormalisasi ke rentang 0–1 menggunakan Persamaan (1).

$$X_{\text{norm}} = X / 255 \quad (1)$$

Pada Persamaan (1), nilai X merupakan nilai piksel asli citra yang berada pada rentang 0–255, sedangkan X_{norm} merupakan nilai piksel hasil normalisasi. Proses normalisasi dilakukan dengan membagi setiap nilai piksel dengan 255 sehingga seluruh data berada pada rentang 0–1. Tahap ini bertujuan untuk menyamakan skala data dan meningkatkan stabilitas proses *clustering*.

3) PENENTUAN PARAMETER CLUSTER

Tahap ini dilakukan pada algoritma K-Means Dasar karena jumlah cluster (K) harus ditentukan sebelum proses *clustering* dimulai. Penentuan jumlah cluster optimal dilakukan menggunakan metode Elbow dan *Silhouette Score*. Pada metode Elbow, nilai *Within Cluster Sum of Squares* (WCSS) dihitung untuk setiap jumlah cluster yang diuji menggunakan Persamaan (2).

$$WCSS = \sum (x_i - c_i)^2 \quad (2)$$

Persamaan (2) digunakan untuk menghitung nilai WCSS, yaitu total jarak kuadrat antara setiap data dengan centroid cluster tempat data tersebut berada. Pada persamaan tersebut, x_i merupakan data ke- i dan c_i merupakan centroid cluster. Semakin kecil nilai WCSS yang dihasilkan, maka semakin dekat anggota cluster terhadap centroidnya sehingga cluster yang terbentuk menjadi lebih kompak. Nilai WCSS kemudian digunakan untuk membentuk grafik Elbow yang membantu menentukan jumlah cluster optimal sebelum proses segmentasi dilakukan.

4) PROSES SEGMENTASI CITRA

Tahap segmentasi dilakukan menggunakan dua algoritma *clustering*, yaitu K-Means Dasar dan *Incremental K-Means*.

A. K-Means Dasar

K-Means Dasar dimulai dengan menentukan jumlah cluster (K) dan memilih *centroid* awal secara acak. Setiap piksel akan dihitung jaraknya terhadap seluruh *centroid*, kemudian dimasukkan ke *cluster* dengan jarak terdekat. Setelah seluruh piksel dikelompokkan, *centroid* diperbarui menggunakan rata-rata seluruh anggota *cluster*. Proses iterasi dilakukan secara berulang hingga *centroid* tidak lagi mengalami perubahan yang signifikan atau jumlah iterasi maksimum tercapai.

B. Incremental K-Means

Incremental K-Means merupakan pengembangan dari K-Means yang tidak memerlukan jumlah *cluster* pada awal proses. Algoritma dimulai dengan satu *centroid* awal yang berasal dari data pertama. Setiap piksel baru akan dibandingkan dengan seluruh *centroid* yang telah terbentuk. Apabila jarak minimum terhadap *centroid* lebih besar dari nilai *threshold* (T), maka *centroid* baru akan dibuat. Sebaliknya, piksel akan dimasukkan ke *cluster* terdekat apabila jaraknya lebih kecil dari nilai *threshold*. Dengan pendekatan ini, jumlah *cluster* dapat terbentuk secara otomatis sesuai karakteristik data yang digunakan.

C. Metrik Jarak

Pada penelitian ini digunakan tiga metode pengukuran jarak, yaitu Euclidean, Manhattan, dan Minkowski. Ketiga metrik jarak tersebut digunakan untuk menentukan kedekatan antara piksel citra dengan *centroid cluster* sehingga dapat diketahui pengaruh masing-masing metode terhadap kualitas segmentasi yang dihasilkan.

1. Euclidean

Jarak Euclidean digunakan untuk menghitung jarak garis lurus antara dua titik dalam ruang multidimensi. Metode ini merupakan metrik jarak yang paling umum digunakan pada algoritma K-Means karena mampu merepresentasikan jarak geometris secara langsung.

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} \quad (3)$$

Persamaan (3) digunakan untuk menghitung jarak antara dua titik pada ruang dua dimensi. Pada persamaan tersebut, (x_1, y_1) dan (x_2, y_2) merupakan koordinat dua titik yang akan dihitung jaraknya, sedangkan d menyatakan nilai jarak Euclidean yang diperoleh. Semakin kecil nilai d , maka kedua titik memiliki tingkat kedekatan yang semakin tinggi. Pada data multidimensi, perhitungan jarak Euclidean dapat diperluas menggunakan Persamaan (4).

$$d = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (4)$$

Persamaan (4) digunakan untuk menghitung jarak antara data dan *centroid* pada ruang berdimensi n . Pada persamaan tersebut, x_i menyatakan nilai data pada dimensi ke- i , y_i menyatakan nilai *centroid* pada dimensi ke- i , sedangkan n merupakan jumlah dimensi data. Dalam penelitian ini, setiap piksel citra direpresentasikan oleh tiga dimensi warna RGB sehingga nilai jarak Euclidean digunakan untuk menentukan *centroid* terdekat pada proses *clustering*.

2. Manhattan

Jarak Manhattan digunakan untuk menghitung jarak berdasarkan jumlah selisih absolut pada setiap dimensi. Metode ini sering disebut *city block distance* karena konsep perhitungannya menyerupai jarak tempuh kendaraan pada jalan kota yang berbentuk blok persegi,

$$d = |x_2 - x_1| + |y_2 - y_1| \quad (5)$$

Persamaan (5) digunakan untuk menghitung jarak Manhattan pada ruang dua dimensi. Pada persamaan tersebut, (x_1, y_1) dan (x_2, y_2) merupakan koordinat dua titik yang dibandingkan, sedangkan d menyatakan nilai jarak Manhattan yang dihasilkan. Berbeda dengan jarak Euclidean yang menghitung jarak garis lurus, jarak Manhattan menjumlahkan seluruh selisih absolut

antar koordinat. Untuk data multidimensi, jarak Manhattan dapat dihitung menggunakan Persamaan (6).

$$d = \sum_{i=1}^n |x_i - y_i| \quad (6)$$

Persamaan (6) digunakan untuk menghitung total selisih absolut antara data dan *centroid* pada seluruh dimensi. Pada persamaan tersebut, x_i merupakan nilai data pada dimensi ke- i , y_i merupakan nilai *centroid* pada dimensi ke- i , dan n merupakan jumlah dimensi data. Nilai jarak yang lebih kecil menunjukkan bahwa data memiliki kemiripan yang lebih tinggi terhadap *centroid* yang dibandingkan.

3. Minkowski

Jarak Minkowski merupakan generalisasi dari jarak Euclidean dan Manhattan. Metode ini memiliki parameter p yang memungkinkan bentuk perhitungan jarak disesuaikan dengan kebutuhan analisis.

$$d = (\sum_{i=1}^n |x_i - y_i|^p)^{\frac{1}{p}} \quad (7)$$

Persamaan (7) digunakan untuk menghitung jarak Minkowski antara data dan *centroid* pada ruang multidimensi. Pada persamaan tersebut, x_i menyatakan nilai data pada dimensi ke- i , y_i menyatakan nilai *centroid* pada dimensi ke- i , n merupakan jumlah dimensi data, sedangkan p merupakan parameter yang mengontrol bentuk perhitungan jarak. Apabila $p = 1$ maka Persamaan (7) akan menjadi jarak Manhattan, sedangkan apabila $p = 2$ maka akan menjadi jarak Euclidean. Dalam penelitian ini digunakan nilai $p = 3$ sesuai implementasi program sehingga diperoleh variasi pengukuran jarak yang dapat dibandingkan dengan Euclidean dan Manhattan dalam proses segmentasi plak citra gigi.

5) EVALUASI DAN HASIL

Evaluasi pada penelitian ini dilakukan menggunakan tiga indikator, yaitu WCSS, *Silhouette Score*, dan waktu komputasi (*running time*). Nilai *Within-Cluster Sum of Squares* (WCSS) digunakan dalam metode Elbow untuk membantu menentukan jumlah *cluster* (K) yang optimal pada algoritma K-Means Dasar. Selanjutnya, kualitas *cluster* hasil segmentasi dievaluasi menggunakan *Silhouette Score* yang mengukur tingkat kesamaan data dalam *cluster* yang sama dan perbedaannya terhadap *cluster* lain. Selain itu, waktu komputasi digunakan untuk mengukur efisiensi algoritma dalam melakukan proses segmentasi citra. Hasil evaluasi dari K-Means Dasar dan *Incremental K-Means* pada masing-masing metrik jarak kemudian dibandingkan untuk menentukan kombinasi algoritma dan metrik jarak yang menghasilkan performa terbaik. Analisis lebih lanjut terhadap hasil evaluasi dibahas pada bagian Hasil dan Diskusi.


III. HASIL DAN DISKUSI

Berdasarkan penelitian yang telah dilakukan, didapatkan hasil pengujian algoritma segmentasi pada citra plak gigi. Bab ini akan meliputi hasil penentuan nilai *cluster* optimal, hasil komputasi waktu algoritma, serta evaluasi kualitas segmentasi yang membandingkan metode K-Means Dasar dan *Incremental K-Means*.

A. PENENTUAN JUMLAH CLUSTER (K) OPTIMAL


Sebelum melakukan proses segmentasi, penentuan jumlah *cluster* yang paling optimal dilakukan menggunakan evaluasi nilai WCSS melalui Metode Elbow. Grafik hasil pengujian WCSS dapat dilihat

pada Gambar 2 yang menunjukkan bahwa penurunan nilai Inertia mulai melandai setelah titik awal. Untuk memvalidasi kekompakan *cluster* secara lebih matematis, metrik *Silhouette Score* digunakan untuk melihat jarak antar anggota *cluster* terhadap *centroid* terdekatnya.



Gambar 2. Grafik Metode Elbow (Inertia vs Jumlah Cluster)

Performa *Silhouette Score* tertinggi mencapai angka 0.61 yang berada tepat pada nilai K=2 dapat dilihat pada Gambar 3. Nilai ini menurun secara konstan seiring dengan bertambahnya jumlah *cluster* yang diujikan (hingga K=10). Hal ini mengindikasikan bahwa secara metrik evaluasi objektif, piksel pada citra plak gigi tersebut paling optimal jika disegmentasi ke dalam 2 kelompok warna utama. Namun, dalam implementasinya, jumlah K dapat disesuaikan kembali (misalnya K=3) apabila kebutuhan analisis medis memerlukan pemisahan antara area gigi normal, plak, dan latar belakang.




Gambar 3. Grafik *Silhouette Score* vs Jumlah Cluster

B. EVALUASI WAKTU KOMPUTASI

Setelah parameter K ditentukan, kedua algoritma diuji menggunakan tiga perhitungan jarak yang berbeda, yaitu *Euclidean*, *Manhattan*, dan *Minkowski*. Pengujian pertama dievaluasi berdasarkan metrik kecepatan atau waktu *running* yang dibutuhkan oleh mesin untuk menyelesaikan segmentasi secara utuh. Gambar 4 menunjukkan adanya perbedaan yang sangat signifikan pada waktu komputasi kedua algoritma. Metode K-Means Dasar terbukti jauh lebih efisien dari segi waktu dibandingkan *Incremental K-Means* di seluruh skenario jarak. Waktu tercepat dicapai oleh K-Means Dasar dengan metrik jarak Manhattan (0.07 detik), sementara waktu terlama dicatat oleh *Incremental K-Means* dengan jarak Manhattan (2.06


detik). Tingginya waktu komputasi pada *Incremental K-Means* disebabkan oleh adanya penambahan fase awal (*thresholding*) di mana algoritma harus menghitung jarak titik secara berulang sebelum masuk ke fase *refinement* standar.



Gambar 4. Grafik Perbandingan Waktu Running K-Means Dasar vs *Incremental K-Means*

C. EVALUASI KUALITAS SEGMENTASI

Selain waktu *running*, kualitas segmentasi dari setiap metode dievaluasi menggunakan *Silhouette Score* untuk mengukur seberapa baik piksel dikelompokkan ke dalam *cluster* yang tepat tanpa adanya tumpang tindih. Gambar 5 mengilustrasikan bahwa metode K-Means Dasar memberikan hasil segmentasi yang jauh lebih baik dan stabil dibandingkan *Incremental K-Means*. K-Means Dasar mencetak skor di kisaran stabil sebesar 0.51 pada ketiga metrik jarak yang diuji (*Euclidean*, *Manhattan*, dan *Minkowski*). Di sisi lain, algoritma *Incremental K-Means* menunjukkan fluktuasi skor yang cukup tinggi dan berada di bawah performa metode standar, dengan skor terendah pada metrik Manhattan (0.3643) dan skor tertinggi pada metrik Minkowski (0.4689). Hal ini menunjukkan bahwa penentuan titik awal *centroid* menggunakan nilai *threshold* pada *Incremental K-Means* belum mampu melampaui keakuratan distribusi acak dari metode standar untuk dataset citra yang digunakan.



Gambar 5. Grafik Perbandingan Kualitas Segmentasi (*Silhouette Score*)

IV. PENUTUP

A. KESIMPULAN

Hasil pengujian algoritma segmentasi citra plak gigi menggunakan metode K-Means Dasar dan *Incremental K-Means* menunjukkan adanya perbedaan performa yang signifikan. Berdasarkan evaluasi nilai WCSS dan *Silhouette Score*, jumlah *cluster* (K) optimal untuk dataset yang digunakan

mengarah pada angka 2. Dalam komparasi kinerja, K-Means Dasar terbukti jauh lebih unggul, baik dari segi efisiensi waktu komputasi maupun kualitas segmentasi. Algoritma K-Means Dasar mencatatkan waktu *running* tercepat sebesar 0,07 detik saat menggunakan metrik jarak Manhattan, serta menghasilkan metrik *Silhouette Score* yang stabil di kisaran 0,51 pada keseluruhan skenario jarak. Sementara itu, *Incremental K-Means* menunjukkan performa yang belum maksimal dengan waktu komputasi yang jauh lebih lama dan tingkat kualitas segmentasi yang berfluktuasi (mencatat skor terendah sebesar 0,36 pada jarak Manhattan). Hal ini menunjukkan bahwa penambahan fase *thresholding* pada *Incremental K-Means* belum mampu melampaui keandalan distribusi acak dari metode K-Means standar untuk karakteristik citra plak gigi yang diuji.

B. SARAN

Untuk meningkatkan kualitas segmentasi pada penelitian selanjutnya, perlu dilakukan optimasi atau penyesuaian yang lebih mendalam terhadap nilai parameter *threshold* (T) pada algoritma *Incremental K-Means*, sehingga inisialisasi *centroid* awal dapat memetakan distribusi warna dengan lebih akurat. Selain itu, ruang warna (*color space*) dari citra yang dianalisis menjadi salah satu faktor penentu kualitas *clustering*. Oleh karena itu, penggunaan ruang warna alternatif selain RGB, seperti HSV atau CIELAB, sangat disarankan untuk dieksplorasi guna melihat apakah batas antara area plak, gigi normal, dan latar belakang dapat tersegmentasi dengan lebih tegas.

REFERENSI

- [1] H. OKTAVIANTO, I. MUHIMMAH, AND T. HIDAYAT, "SEGMENTASI AREA GIGI MENGGUNAKAN FUZZY C-MEANS," *JURNAL TEKNOLOGI INFORMASI DAN TERAPAN*, VOL. 4, NO. 2, PP. 75–82, APR. 2017, DOI: 10.25047/JTIT.V4I2.63.
- [2] N. SALARI, N. DARVISHI, M. HEYDARI, S. BOKAEE, F. DARVISHI, AND M. MOHAMMADI, "GLOBAL PREVALENCE OF CLEFT PALATE, CLEFT LIP AND CLEFT PALATE AND LIP: A COMPREHENSIVE SYSTEMATIC REVIEW AND META-ANALYSIS," *J. STOMATOL. ORAL MAXILLOFAC. SURG.*, VOL. 123, NO. 2, PP. 110–120, APR. 2022, DOI: 10.1016/J.JORMAS.2021.05.008.
- [3] E. F. A. PRATAMA, K. KHAIRIL, AND J. JUMADI, "IMPLEMENTASI METODE K-MEANS CLUSTERING PADA SEGMENTASI CITRA DIGITAL," *JURNAL MEDIA INFOTAMA*, VOL. 18, NO. 2, PP. 291–301, OCT. 2022, DOI: 10.37676/JMI.V18I2.2899.
- [4] D. T. PHAM, S. S. DIMOV, AND C. D. NGUYEN, "AN INCREMENTAL K-MEANS ALGORITHM," *PROC. INST. MECH. ENG. C J. MECH. ENG. SCI.*, VOL. 218, NO. 7, PP. 783–794, JUL. 2004, DOI: 10.1243/0954406041319509; WEBSITE: WEBSITE: SAGE; REQUESTED JOURNAL: JOURNAL: PICB; WGROUPO: STRING: PUBLICATION.
- [5] A. PREMANA, R. M. H. BHAKTI, AND D. PRAYOGI, "SEGMENTASI K-MEANS CLUSTERING PADA CITRA MENGGUNAKAN EKSTRAKSI FITUR WARNA DAN TEKSTUR," *JURNAL ILMIAH INTECH: INFORMATION TECHNOLOGY JOURNAL OF UMUS*, VOL. 2, NO. 01, PP. 89–97, MAY 2020, DOI: 10.46772/INTECH.V2I01.190.